

Diseño reproducible del flujo experimental

Chatbot educativo de física preuniversitaria basado en IA generativa (LLM + RAG) · Dominio: cinemática

Alumno: Elmer Dante Rojas Zuta

Docente: Glen Dario Rodriguez Rafael

Tipo de tesis: LLM + RAG

Fecha: setiembre de 2026

Estado de cada decisión en las páginas 2–3: **D** definida en el proyecto **P** propuesta preliminar de este diseño **E** parámetro que se calibra solo con Desarrollo/Validación




Figura 1. Una consulta recorre la banda B de izquierda a derecha; el índice (A) se construye una vez por versión del corpus; la batería (C) aporta preguntas y referencias pero nunca entra al corpus; la banda D muestra dónde se ajusta el sistema (solo con Desarrollo y Validación) y el congelamiento previo a Test. WhatsApp solo transporta mensajes: el núcleo evaluado offline es el mismo que atiende al estudiante. * Sujeta al supuesto S1.

Supuestos declarados (a confirmar)

- S1.** El corpus de cinemática tendrá del orden de cientos a pocos miles de chunks; si fuera mucho mayor, se usaría un índice aproximado y se registraría su configuración.
- S2.** Habrá un segundo docente de física para calificar una muestra; si no, se aplica la alternativa descrita en la p. 3.
- S3.** Habrá acceso por API a al menos dos LLM de distinto costo durante todo el experimento.

Alcance y límites del experimento

- El flujo evalúa offline la calidad técnica del pipeline (HE2; OE2–OE3). El pre-test/post-test del piloto (OE4) es un estudio posterior que usa la configuración congelada.
- La batería evalúa la **primera respuesta** a cada consulta. La tutoría socrática de varios turnos se evalúa en el piloto, con una muestra de conversaciones calificadas con la misma rúbrica.
- El modo de evaluación formativa previsto en OE3 no forma parte de este flujo.
- No se entrena ningún modelo: el ajuste es de configuración, no de pesos.

1. Descripción técnica por etapa

Etapa	Entrada	Proceso reproducible	Salida / artefacto	Parámetro a fijar
Corpus	Separatas, teoría, fórmulas, ejemplos resueltos, criterios, FAQ	Inventario con ID y fuente; transcripción y verificación manual de fórmulas; limpieza; regla de exclusión.	corpus_vX + manifiesto con hash	D fuentes validadas por el docente P reglas de normalización
Chunking	corpus_vX	Regla preliminar: un chunk = una unidad semántica completa (definición; fórmula + variables + unidades; procedimiento; ejemplo resuelto con su solución). Si excede L_{max} , se divide por pasos repitiendo el encabezado. Metadatos: tema, subtema, tipo, fuente.	chunks_vX, cada uno ligado a su unidad fuente	P regla de unidad semántica E L_{max} (solapamiento solo si se divide)
Embeddings e índice	Chunks	Un modelo de embeddings multilingüe, el mismo para documentos y consultas; vectores normalizados; índice exacto (S1).	Matriz de vectores + índice_vX	P modelo y versión de embeddings
Consulta y preproc.	Mensaje del estudiante o ítem de la batería	Normaliza texto, números y unidades. Saludos y agradecimientos (lista de patrones) reciben una respuesta de plantilla y no entran al pipeline. En el piloto, la consulta se concatena con los N turnos previos antes de vectorizar.	Consulta normalizada + vector	P lista de patrones P N = 2 turnos (sin efecto en la batería)
Retrieval	Vector de consulta; índice	Similitud coseno, top-k. BM25 como referencia léxica. Reranking: no en v1; se evalúa solo si Recall@k es alto y MRR bajo.	Top-k: ID, score, rango	P k inicial = 5 E $k \in \{3, 5, 8\}$ E reranking sí/no
Selección de contexto	Top-k con scores	Descarta chunks con score $< \tau$ y limita tokens de contexto. Si ninguno supera τ , abstención de nivel 1; como el corpus es solo de cinemática, el mismo umbral detecta las consultas fuera de dominio.	Contexto final (IDs) o abstención	E τ (criterio en el recuadro de abstención) P tokens máximos de contexto
Prompt	Plantilla; contexto; consulta	Plantilla versionada + contexto etiquetado con IDs + consulta. Sin cambios después del congelamiento.	Prompt final (texto + hash)	P plantilla v0.1 D rol socrático y nivel preuniversitario
LLM	Prompt final	Llamada por API con un ID de modelo fechado (no alias <i>latest</i>) y parámetros fijos; salida JSON validada; un reintento registrado si falla el formato.	JSON: decisión, solución interna, mensaje, fuentes	E modelo (regla de selección, p. 3) P T = 0; max_tokens; seed si existe
Respuesta y registro	JSON del LLM	Verifica que las fuentes citadas estén en el contexto; solo <i>mensaje_estudiante</i> llega a WhatsApp; escribe el log.	Log JSONL por <i>run_id</i>	P esquema de log D anonimización

Plantilla inicial del prompt (v0.1)

[SISTEMA] Eres tutor de física preuniversitaria (cinemática: MRU, MRUV, caída libre, tiro parabólico, movimiento circular). Tu meta es que el estudiante razone, no darle solo el resultado.

- Usa SOLO el CONTEXTO para conceptos, fórmulas y criterios; cita los [ID] que uses.
- En ejercicios, guía por pasos: datos → tipo de movimiento → ecuación → sustitución y unidades → interpretación. Cierra con UNA pregunta orientadora; no des el valor final si el estudiante aún no lo ha intentado.
- Usa lenguaje claro de nivel preuniversitario y unidades SI.
- Si el CONTEXTO no sustenta la respuesta, no improvises: dilo, pide reformular o sugiere consultar al docente.

Responde solo en JSON: {"decision": "responder" | "abstener", "solucion_interna": "...", "mensaje_estudiante": "...", "fuentes": ["ID", "...]}

[USUARIO] CONTEXTO: [ID_1] texto ... [ID_n] texto · CONSULTA: {pregunta}

solucion_interna no se muestra al estudiante: permite medir la corrección aunque la guía socrática oculte el resultado, a cambio de más tokens de salida. El baseline sin RAG usa la misma plantilla sin CONTEXTO ni regla 1.

Política de abstención

- Nivel 1 (retrieval):** si ningún chunk alcanza τ , se envía un mensaje estándar sin llamar al LLM.
- Nivel 2 (generación):** el LLM devuelve *abstener* si el contexto no sustenta la respuesta.
- Mensaje:** reconoce el límite, pide reformular o deriva al docente; nunca inventa.
- Evidencia suficiente** en un ejercicio nuevo significa que el método y las fórmulas están en el corpus, no el ejercicio idéntico.
- Calibración de τ :** en Validación se elige el valor que maximiza la exactitud balanceada de la decisión responder/abstener (preguntas respondibles frente a no respondibles).

Control experimental

- Partición estratificada por subtema × tipo de pregunta; las variantes de un mismo problema van al mismo conjunto.
- Deduplicación batería–corpus y entre conjuntos (similitud + revisión manual).
- Desarrollo ajusta; Validación calibra y selecciona; Test se abre una sola vez, con el *config_hash* registrado antes.

2. Evaluación

Dimensión	Métrica	Qué mide y por qué se incluye
Retrieval	Recall@k (principal); MRR	Recall@k indica si la evidencia llega al LLM; MRR, si conviene reducir k o añadir reranking. La relevancia se anota por unidad fuente, así sobrevive a cambios de chunking. NDCG/MAP no se usan: hay 1–2 unidades relevantes por pregunta, sin grados de relevancia.
Generación	Corrección (principal); fidelidad, calidad pedagógica, alucinación, abstención	Corrección: solución interna frente a la referencia (correcta/parcial/incorrecta). Fidelidad y pedagogía (guía socrática, nivel, claridad; escala 1–4 preliminar) actúan como restricciones, no como objetivos. Abstención: correcta en no respondibles, indebida en respondibles. Calificación ciega (configuración oculta, orden aleatorio).
Confiabilidad	Kappa ponderado	Un segundo docente califica ~25 % de Test (S2). Si no hay, se recalifica a ciegas la misma muestra dos semanas después y se declara como fiabilidad intraevaluador.
Operación	Tokens, latencia p50/p95, costo	Costo = tokens × precio de una tabla fechada en la configuración. La latencia se mide en el núcleo; la de extremo a extremo, en el piloto.
Baseline	RAG vs. LLM sin RAG; denso vs. BM25	Contrasta HE2 con el mismo LLM y la misma plantilla. Pruebas pareadas: McNemar (corrección), Wilcoxon (rúbrica), intervalos bootstrap.

Regla de selección de configuración (se fija antes de Validación). Entre las configuraciones que cumplen en Validación las restricciones de fidelidad, pedagogía y latencia, se elige la de **menor costo por consulta** cuya corrección no sea inferior a la mejor en más de δ puntos. δ se acuerda con el asesor antes de ver los resultados. En Test se ejecutan la elegida, la de mayor corrección y el baseline, y se reportan todas.

3. Reproducibilidad

- **Versionado:** corpus, chunks, embeddings e índice con hash; plantilla vN; commit de Git en cada ejecución.
- **Configuración única** (*config.yaml*): modelo fechado, embeddings, k, τ , $L_{\max}$, N, T, max_tokens, seed y tabla de precios. Su hash identifica la configuración.
- **Log por consulta:** run_id, config_hash, fecha; consulta; IDs, scores y rango del top-k; contexto y prompt finales; JSON de respuesta; decisión; tokens; latencia; costo; ID de modelo devuelto por la API. Lo constante en una configuración se guarda una sola vez.
- **No determinismo:** T = 0, seed y modelo fechado reducen la variación, pero no garantizan textos idénticos. Se reproduce la configuración, no el texto exacto. Se ejecutan 30 preguntas fijas de Validación 3 veces por configuración y se reporta la concordancia de decisión y de corrección. El retrieval es determinista.

4. Partición de la batería (preliminar)

Conjunto	n	Uso
Desarrollo	200 (50 %)	Ajuste de prompt, chunking y k
Validación	80 (20 %)	Calibrar τ y k; aplicar la regla de selección; fijar umbrales
Evaluación final	120 (30 %)	Una ejecución con la configuración congelada

Sustituye a 280/60/60: sin entrenamiento, el tamaño de Test determina la precisión de las comparaciones (IC 95 % de ± 10 pp con $n = 60$ frente a ± 7 pp con $n = 120$, para un acierto cercano a 0,80). Cada conjunto se estratifica por los 5 subtemas e incluye ~10–15 % de preguntas no respondibles. Por validar con el asesor.

Criterio preliminar de éxito

Evidencia pertinente, respuestas correctas y fieles, guía socrática adecuada, abstención apropiada, costo y latencia viables y configuración repetible. Los umbrales numéricos y δ se registran con fecha y hash **antes** de abrir Test y no se modifican después.

5. Riesgos técnicos y mitigación

Riesgo	Mitigación	Riesgo	Mitigación
Alucinación	Contexto obligatorio; citas verificadas; rúbrica de fidelidad	Sesgo del evaluador	Calificación ciega; segundo evaluador o recalificación; kappa
Retrieval incorrecto	Recall@k/MRR por subtema; análisis de errores en Desarrollo	Respuesta no socrática	Regla en el prompt; restricción pedagógica en la selección
Evidencia insuficiente	Abstención en dos niveles; ítems no respondibles	Costo y latencia	Estimación con Desarrollo; tope de max_tokens; regla de menor costo
Fórmulas mal extraídas	Transcripción manual; auditoría de una muestra	Seguimientos sin contexto	Historial de N turnos; evaluación de diálogos en el piloto
Fuga y contaminación	Partición por familias; deduplicación; Test sellado; exclusión del pre/post-test	API externa y no determinismo	Modelo fechado; ID registrado; Test en una sola ventana temporal; repeticiones